

Ouvidoria Municipal — Busca Semântica de Manifestações

Relatório síntese · Processamento de Linguagem Natural — representações vetoriais, busca semântica e chunking

Aluno: Bruno Dutra

1. Escopo e organização

O trabalho constrói um sistema de apoio à triagem de manifestações de uma ouvidoria municipal: dado um corpus de 40 manifestações em cinco categorias oficiais, o sistema precisa (a) encontrar manifestações semanticamente parecidas com uma descrição livre do cidadão, (b) apontar duplicatas — o mesmo problema relatado duas vezes com palavras diferentes — e (c) lidar com relatos longos, que misturam vários problemas num só texto.

Arquivo	Conteúdo
análise_comparativa.ipynb	Entrega 1 — BoW × TF-IDF × embeddings nos três pares do enunciado
deteccao_duplicatas.ipynb	Entrega 2 — <code>detectar_duplicatas()</code> , calibração do limiar, análise de erros
chunking_manifestacoes.ipynb	Entrega 3 — <code>RecursiveCharacterTextSplitter</code> , overlap, projeções 2D
app_ouvidoria.py	Entrega 4 — aplicação Streamlit com as quatro abas
utils_ouvidoria.py	Carga do corpus, registro de modelos, paleta — compartilhado
data/manifestacoes.csv	O corpus (40 manifestações)
data/gabarito_duplicatas.csv	Anotação manual dos pares duplicados e quase-duplicados
data/gerar_dataset.py	Script que gera o corpus e valida suas restrições

Execução: `pip install -r requirements.txt` e depois `streamlit run app_ouvidoria.py`. Os notebooks estão com todas as saídas já executadas.

2. Decisões de projeto

2.1 Corpus sintético, com armadilhas deliberadas. O corpus foi gerado por `data/gerar_dataset.py`, que valida por asserção as restrições do enunciado: 40 manifestações, 8 por categoria, textos entre 50 e 800 caracteres, 5 relatos acima de 500 caracteres e 6 duplicatas semânticas (15%). Além disso, foram incluídos quatro pares **quase-duplicados** — mesmo tipo de problema em **loais diferentes**, como "poste apagado na Rua das Acácias" × "lâmpada queimada na praça do bairro Aparecida". Sem eles a detecção de duplicatas seria trivial e a análise de falsos positivos, vazia; com eles, o problema fica realista, porque é exatamente esse par que um sistema real erra.

2.2 Modelos de embedding. O enunciado sugere `BAAI/bge-small-pt-v1.5`, mas esse repositório **não existe no HuggingFace Hub** (retorna 404). No lugar dele foi adotado o `paraphrase-multilingual-MiniLM-L12-v2`, usado como padrão em todos os resultados deste relatório. O registro em `utils_ouvidoria.py` mantém quatro modelos, todos selecionáveis na barra lateral do app: `MiniLM-L12-v2` (padrão, leve), `mpnet-base-v2` (maior e mais preciso), `distiluse-base-multilingual-cased-v1` e `multilingual-e5-small` — este último exige o prefixo `query:` nos textos, aplicado automaticamente pelo código.

2.3 O limiar pertence ao modelo, não ao problema. A decisão mais consequente do trabalho. Em vez de fixar 0,85 no código, o limiar é calibrado contra o gabarito para cada modelo, e o app troca o limiar junto com o seletor de modelo.


2.4 Chunking. Duas estratégias de separadores foram comparadas: a padrão do `LangChain` (`["\n\n", "\n", " ", ""]`, que corta no meio da frase em textos corridos) e uma consciente de frases (ponto, ponto-e-vírgula, vírgula). A

configuração recomendada é `chunk_size` 300 com `chunk_overlap` 90 — pelos motivos da seção 3.3, que não são os que esperávamos no início.

2.5 Visualização. A paleta das cinco categorias foi verificada quanto a contraste e separação para daltonismo; como a separação fica na faixa que exige reforço, **todo gráfico de dispersão codifica a categoria pela cor e também pelo formato do marcador**, nunca só pela cor. Os mapas de calor de similaridade usam rampa sequencial de um único tom, e não arco-íris, porque codificam magnitude.

3. Resultados

3.1 Entrega 1 — as representações esparsas falham no caso central




O resultado mais expressivo não é que os embeddings sejam melhores — é **como** as representações esparsas erram. Em BoW, o par `M008` x `M031`, que trata de assuntos completamente diferentes (falta de médico x lâmpada queimada), marca **0,32**, quase três vezes o valor de **0,12** do par `M003` x `M017`, que relata o mesmo buraco na mesma avenida. A ordem está invertida: um sistema baseado em BoW agruparia "falta de médico" com "lâmpada queimada" antes de agrupar duas denúncias do mesmo buraco.

A causa fica clara ao listar os termos em comum: `M003` e `M017` compartilham apenas *da, equipe, está, nenhuma*, enquanto `M008` e `M031` compartilham seis palavras, todas funcionais. O vocabulário de conteúdo dos dois relatos do buraco é disjunto — *buraco* x *esburacado*, *Av. Brasil* x *avenida principal*, *consertar* x *tapar*.

Remover stopwords corrige o falso positivo (o par não relacionado cai de 0,32 para 0,05) mas **não cria** a similaridade ausente (o par duplicado vai de 0,12 para apenas 0,10). Limpar vocabulário não inventa sinônimos.

No teste de busca — que é o uso real — a consulta *"não tem médico atendendo no posto do meu bairro"* é o caso mais favorável possível para as representações esparsas, porque contém literalmente "médico" e "posto". Ainda assim o BoW devolve em primeiro lugar uma manifestação sobre **falta de vaga em creche**, e nenhuma das quatro variantes esparsas recupera `M022` ("falta atendimento no PSF") entre as três primeiras. Os embeddings devolvem `M008` e `M022` nas duas primeiras posições.

3.2 Entrega 2 — o limiar de 0,85 não encontra nada



Com o limiar padrão de 0,85, `detectar_duplicatas()` retorna **zero pares**: as seis duplicatas reais ficam entre 0,54 e 0,78, e o par mais similar de todo o corpus chega a 0,78. Não há nada acima de 0,85 para encontrar — 6 falsos negativos, 100% de erro.

Calibrando contra o gabarito, o F1 máximo (0,67) ocorre em **0,68**, com 4 verdadeiros positivos, 2 falsos positivos e 2 falsos negativos. O percentil 90 sugerido como alternativa dinâmica cai em 0,455 e marcaria **78 pares** — 13 vezes mais do que existe — porque duplicatas são menos de 1% dos 780 pares; p99 (0,65) seria o ponto de partida razoável para um critério dinâmico.

Os **falsos positivos** são exatamente as armadilhas plantadas: `M024` × `M031` (iluminação apagada em locais diferentes) e `M014` × `M026` (falta de água em escola × em posto de saúde). Nos dois casos o modelo está semanticamente certo e operacionalmente errado — e esse é o limite estrutural da abordagem: **similaridade semântica não é identidade de ocorrência**. Duas denúncias são o mesmo chamado quando coincidem em problema e local e janela de tempo; só o primeiro está no vetor.

Os **falsos negativos** têm origem oposta: em `M012` × `M035` um cidadão descreve o assalto do ponto de vista de quem sofre e o outro do ponto de vista do observador, com sujeito, objeto e tempo verbal diferentes.

Como os dois erros custam coisas diferentes — um falso positivo funde dois chamados legítimos e deixa um cidadão sem atendimento; um falso negativo apenas gera retrabalho — a recomendação final não é um corte único, e sim uma **faixa de triagem**: acima de 0,75, duplicata provável; entre 0,68 e 0,75, conferência humana; abaixo, chamados independentes. Com ela, as duas quase-duplicatas caem na zona de revisão e nenhum chamado legítimo é fundido automaticamente.

O limiar ótimo varia bastante entre modelos (0,68 no MiniLM, 0,71 no mpnet, 0,50 no distiluse, 0,93 no e5), porque cada modelo ocupa uma faixa própria da escala de cosseno.

3.3 Entrega 3 — o overlap que não acontecia

O achado mais surpreendente do trabalho. Ao comparar configurações com separadores conscientes de frase, as métricas de `450/0` e `450/135` saíram **idênticas**, o que não fazia sentido. Medindo o overlap **realizado** — o maior sufixo de um chunk que é prefixo do seguinte — a causa apareceu:

separadores	overlap pedido	overlap realizado
palavra (padrão)	90	86,0
frase	90	5,5
frase	225	184,8

O `chunk_overlap` é um orçamento em caracteres, mas o splitter o gasta em **unidades inteiras do separador que acabou usando**. Quando os átomos são palavras, quase sempre cabe; quando são frases de ~150 caracteres, um or-

çamento de 90 não compra nenhuma, e a sobreposição é silenciosamente descartada. Comparar configurações pelo parâmetro *pedido* levaria à conclusão falsa de que "o overlap não faz diferença".

Com o overlap de fato acontecendo, a coesão entre chunks consecutivos sobe de 0,438 para 0,616 (`chunk_size` 300, overlap de 0 a 30%) — mas boa parte disso é **inflação mecânica**, já que vizinhos passam a compartilhar texto literal. A evidência de ganho real é a **fidelidade ao relato de origem**, que não pode ser inflada por repetição e sobe de 0,694 para 0,750. O papel do overlap é, portanto, **reduzir a perda nas fronteiras**, não acrescentar informação — e o efeito é maior quanto menor o chunk, porque chunks pequenos têm mais fronteiras.

O que se perde numa fronteira é concreto: com separadores de frase e overlap zero, 22% dos chunks abrem dependendo do chunk anterior — "*Além disso, os ventiladores de duas salas queimaram em março...*", lido isoladamente pelo buscador, **não diz de qual escola se trata**.

No teste de recuperação, todas as configurações com chunk acertam as cinco consultas, com margem sobre o segundo colocado cerca de três vezes maior que a do índice de documentos inteiros — que erra a consulta sobre o aparelho de nebulização quebrado, detalhe enterrado na última frase de um relato de 668 caracteres. **Entre as configurações, porém, o teste não discrimina**: as margens ficam num intervalo estreito e a ordem se inverte por ruído (`150/45` marca 0,242; `300/90`, 0,234). Com cinco consultas, essa diferença não é evidência. A escolha de `300/90` apoia-se então na fidelidade ao documento, lida como ponto de equilíbrio e não como métrica a maximizar: um chunk igual ao documento inteiro teria fidelidade 1,0 e anularia o propósito do chunking.

Nas projeções 2D, os chunks de uma mesma manifestação formam grupos identificáveis, com separação positiva entre irmãos e não-irmãos nas cinco manifestações (média 0,238) — mas **sem colapsar num ponto**, o que é o esperado: relatos longos são multi-assunto por natureza, e se os chunks fossem idênticos entre si o chunking não teria acrescentado nada.

3.4 Entrega 4 — o app

A aplicação tem as quatro abas pedidas, com seletor de modelo e top-k configurável na barra lateral, `st.cache_resource` para o modelo e `st.cache_data` para os embeddings. Três decisões de interface merecem registro:

- **os scores vêm com rótulo textual** ("similaridade alta/média/baixa") além da cor, para não depender de percepção cromática;
- **a aba de chunking exibe o overlap realizado ao lado do pedido** e emite um alerta quando o parâmetro não está sendo obedecido — o achado da seção 3.3 virou funcionalidade;
- **o limiar de duplicata acompanha o modelo escolhido**, e a aba Base Completa avisa quando nenhum par o atinge, em vez de exibir uma tabela vazia sem explicação.

Na aba Espaço Vetorial, a comparação entre clusters semânticos e categorias oficiais dá $ARI = 0,656$ no modelo padrão (0,38 a 0,66 conforme o modelo): bem acima do acaso, ainda assim longe da correspondência exata. A divergência não é erro do modelo — as categorias são **administrativas** (dizem qual secretaria atende), não semânticas. "Escola sem água" é *educação* e "posto sem água" é *saúde*, mas descrevem o mesmo fato. Isso sugere um uso adicional: proximidade semântica como detector de **encaminhamento administrativo duvidoso**.

4. Dificuldades encontradas

1. **Um modelo inexistente no enunciado.** `BAAI/bge-small-pt-v1.5` retorna 404; foi preciso testar candidatos e escolher um substituto.
2. **Um limiar impraticável no enunciado.** 0,85 não detecta nada neste corpus. Em vez de forçar o corpus a caber no número, o trabalho calibrou o número — e o caminho até essa decisão consumiu boa parte do esforço da Entrega 2.
3. **O overlap silenciosamente inerte.** Foi a dificuldade mais difícil de perceber, porque nada falha: o código roda, devolve chunks e produz métricas plausíveis. Só a coincidência exata entre duas configurações denunciou o problema.
4. **Métricas que enganam.** A razão entre a média das duplicatas e a média dos demais pares é *maior* no TF-IDF sem stopwords (5,8) do que nos embeddings (2,5) — não porque ele separe melhor, mas porque o denominador

colapsou para 0,024.

5. **Escalas incomparáveis entre modelos.** O `multilingual-e5-small` mantém quase todos os pares acima de 0,89 e exige prefixo `query:` ; sem isso, parece simplesmente ruim.
 6. **Ambiente.** Python 3.14 em Apple Silicon, com instalação de `torch` e `sentence-transformers` no `venv` do projeto.
-

5. Aprendizados

- **Limiares pertencem ao modelo, não ao problema.** Qualquer constante de similaridade copiada de um tutorial é suspeita até ser recalibrada nos próprios dados.
 - **Meça o que aconteceu, não o que você pediu.** O `chunk_overlap` é o exemplo mais claro: o parâmetro configurado e o efeito realizado podem divergir sem nenhum erro.
 - **Uma métrica isolada quase sempre engana.** Coesão entre chunks sobe por repetição; razões entre médias explodem com denominadores pequenos; F1 empata escondendo perfis de erro opostos. A saída foi sempre cruzar duas medidas com mecanismos diferentes.
 - **Amostras pequenas não ordenam alternativas próximas.** Cinco consultas bastam para mostrar que chunkar é melhor que não chunkar, mas não para eleger a melhor configuração.
 - **O custo do erro é assimétrico e deve entrar na decisão.** Fundir dois chamados legítimos deixa um cidadão sem atendimento; deixar passar uma duplicata gera retrabalho. A faixa de revisão humana existe por causa dessa assimetria, não por indecisão técnica.
 - **Similaridade semântica não é identidade de ocorrência.** Talvez o aprendizado mais transferível: o vetor captura *sobre o que* o texto fala, não *qual evento específico* ele relata.
-

6. Limitações e próximos passos

O corpus é **sintético** e pequeno (40 manifestações), construído pelo próprio autor — o que significa que as duplicatas são mais bem-comportadas do que as de uma ouvidoria real, onde há erros de digitação, abreviações, texto em caixa alta e relatos truncados. Os números de precisão e revocação devem ser lidos como demonstração de método, não como desempenho esperado em produção.

Três extensões naturais:

1. **Extração de entidades de local e tempo.** É o que falta para separar duplicata verdadeira de quase-duplicata. A similaridade semântica viraria o primeiro filtro; a coincidência de logradouro e período, a confirmação.
2. **Avaliação com mais consultas e anotação independente.** Para poder comparar configurações de chunking com significância.
3. **Reranking dos candidatos.** Um *cross-encoder* sobre os 20 primeiros resultados tende a resolver justamente os casos ambíguos da faixa de revisão, ao custo de mais processamento por consulta.